РЕФЕРАТ

Пояснительная записка в одной книге: 38 с., 4 рис., 14 табл., 9 источников, 1 прил.

НЕЧЁТКАЯ ВЕЛИЧИНА, РАСПРЕДЕЛЕНИЕ РЭЛЕЯ, ФУНКЦИЯ ПРИНАДЛЕЖНОСТИ, АЛЬФА-СРЕЗ, ИНТЕРВАЛЬНАЯ АРИФМЕТИКА, КЛАСТЕРИЗАЦИЯ, GAP STATISTIC, HDBSCAN, PYTHON

Объект разработки - программный комплекс для работы с нечёткими величинами формы Рэлея. Цель работы - реализовать представление величин, арифметические операции и кластерный анализ их множества.

Использованы нормировка плотности по максимуму, представление через α-срезы, интервальная арифметика, иерархическая кластеризация полной связью, критерий Gap и алгоритм HDBSCAN.

Разработаны независимые вычислительные библиотеки и локальный графический интерфейс. Реализованы воспроизводимая генерация, сравнение методов, отбор внутри групп и восстановление сессии. Корректность подтверждена контрольными расчётами и 125 автоматическими проверками.

Область применения - учебные исследования нечётких величин и сравнение способов кластеризации. В записке приведены математическая модель, архитектура, порядок установки и работы пользователя.

СОДЕРЖАНИЕ

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ 4

ВВЕДЕНИЕ 5

1 Общая характеристика программы 6

2 Математический аппарат 7

2.1 От случайной величины к нечёткой 7

2.2 Нормировка по максимуму 7

2.3 Представление через α-срезы 8

2.4 Арифметические операции 10

2.5 Сравнение и расстояние 12

3 Кластеризация полной связью 15

3.1 Последовательность вычислений 15

3.2 Три способа остановки 15

3.3 Выбор числа групп по Gap 16

3.4 Сравнение с HDBSCAN 18

3.5 Отбор по соответствию кластеру 20

4 Моделирование набора 21

4.1 Воспроизводимость 21

4.2 Зачем сохраняются метки источников 22

5 Архитектура программы 23

6 Получение и установка программы 25

6.1 Требования 25

6.2 macOS и Linux: установка в виртуальное окружение 25

6.3 Windows: установка без активации окружения 25

6.4 Использование только библиотек 26

6.5 Запуск и готовность 26

7 Работа пользователя 28
7.1 Порядок работы с моделью 28
7.2 Порядок выполнения операции 28
7.3 Набор и кластеры 29
8 Проверка правильности объединения 31
8.1 Контрольные сценарии: N = 150, seed = 42 31
8.2 Как трактовать ARI 32
9 Файлы и контроль работы 34
9.1 Сохранение и восстановление 34
9.2 Испытания 34
9.3 Ограничения и обработка ошибок 35
ЗАКЛЮЧЕНИЕ 36
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 37
Приложение А Сборка пояснительной записки 38

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

API - программный интерфейс библиотеки;
ARI - скорректированный индекс Рэнда для сравнения разбиений;
CSV - текстовый формат табличных данных;
Gap - критерий выбора числа кластеров;
HDBSCAN - алгоритм плотностной иерархической кластеризации;
JSON - текстовый формат сохранения сессии;
K - число кластеров;
N - число нечётких величин в наборе;
T - порог расстояния;
α - уровень принадлежности;
ε - порог отсечения хвоста функции;
σ - положительный параметр масштаба величины Рэлея.

ВВЕДЕНИЕ

Нечёткие величины применяются для представления численных характеристик, значения которых описываются степенью принадлежности, а не одним точным числом. Работа с множеством таких величин требует согласованных способов отображения, выполнения операций и оценки сходства.

В рамках практического занятия по дисциплине «Неклассические логики» рассматривается вариант 9: функция принадлежности строится на основе формы распределения Рэлея. Цель разработки состоит в создании локальной программы, позволяющей исследовать эту модель и распределять множество нечётких величин по кластерам.

Для достижения цели требуется выбрать представление величины, реализовать сложение, вычитание, умножение, деление и сравнение, подготовить генератор наборов и средства кластерного анализа. Вычислительные процедуры должны быть пригодны для независимого использования внешними программами.

В разработанном комплексе вычисления выполняются через α-срезы. Пользователь может сравнить полную связь с автоматическим выбором числа групп и HDBSCAN, проверить разбиение на синтетических данных и сохранить результаты. В записке последовательно изложены модель, алгоритмы, архитектура, установка, порядок работы и способы контроля.

1 Общая характеристика программы

Программный комплекс предназначен для представления нечётких величин формы Рэлея, выполнения операций над ними и кластерного анализа множества таких величин. Он разработан для комплексного практического занятия по дисциплине «Неклассические логики» [1].

Единицей данных является отдельная нечёткая величина со своим $\sigma > 0$. Набор из 150 объектов содержит 150 функций принадлежности, а не 150 случайных значений одной функции. Принадлежность каждого x описывает его согласованность с моделью величины.

Соответствующие сведения приведены в таблице 1.

Таблица 1 - Основные функции программы

Группа функций	Что выполняет программа
Представление	Ввод σ; построение кривой; выбор α и отображение границ среза
Манипулирование	Сложение, вычитание, умножение, деление, сравнение по рангу; сохранение результата
Подготовка данных	Генерация 100-300 величин по семи сценариям; редактирование σ
Анализ	Полная связь: ровно K, порог T или автоматический выбор K; сравнение с HDBSCAN и отбор по α
Обмен	Сохранение и загрузка JSON-сессии; выгрузка таблицы CSV
Вспомогательные	Проверка параметров, поиск границ, интерполяция, ранжирование, расчёт расстояний и ARI

После установки зависимостей интернет для расчётов не требуется. В приложении четыре раздела: «Модель», «Операции», «Набор» и «Кластеры». Журнал действий в этой версии отключён по выбранному составу интерфейса; технический вывод сервера остаётся доступен для диагностики.

2 Математический аппарат

2.1 От случайной величины к нечёткой

За основу формы берётся плотность распределения Рэлея без сдвига [2]. Она возникает, например, как распределение длины вектора с двумя независимыми нормальными компонентами с нулевыми средними и одинаковым масштабом σ. В данной работе используется именно форма этой плотности, а её вероятностный смысл заменяется смыслом принадлежности.

$$f(x;\sigma) = (x / \sigma^2) \cdot \exp[-x^2 / (2\sigma^2)],\ x > 0,\ \sigma > 0. \tag{1}$$

где $f(x; \sigma)$ - плотность распределения Рэлея;
x - значение случайной величины;
σ - положительный параметр масштаба.

При $x \leq 0$ значение равно нулю. Параметр σ меняет ширину и положение вершины; отдельный параметр сдвига не вводится.

2.2 Нормировка по максимуму

$$\begin{gathered} d \ln f / dx = 1/x - x/\sigma^2 = 0 \Rightarrow x = \sigma. \\ f(\sigma;\sigma) = \exp(-1/2) / \sigma. \end{gathered} \tag{2}$$

где $f(\sigma; \sigma)$ - значение плотности в точке максимума;
σ - параметр масштаба.

Делим плотность на значение в вершине. Получаем функцию принадлежности с максимумом 1:

$$\begin{gathered} \mu_\sigma(x) = (x / \sigma) \cdot \exp[(1 - x^2/\sigma^2) / 2],\ x > 0; \\ \mu_\sigma(x) = 0,\ x \leq 0. \end{gathered} \tag{3}$$

где $\mu\sigma(x)$ - степень принадлежности значения x нечёткой величине;
σ - параметр масштаба исходной функции.

Почему высота равна единице. Подставим в функцию принадлежности координату её вершины x = σ:

$$\mu_{\sigma}(\sigma) = (\sigma / \sigma) \exp[(1 - \sigma^2/\sigma^2) / 2] = \exp(0) = 1. \quad (4)$$

где μσ(σ) - принадлежность значения в вершине;
σ - положительный параметр масштаба.

Оба отношения σ/σ и σ²/σ² равны 1, поэтому показатель экспоненты становится нулём. Например, при σ = 2 максимум исходной плотности равен примерно 0,303265. Деление плотности на этот же максимум даёт в вершине 0,303265 / 0,303265 = 1. Это выбранная нормировка шкалы принадлежности. Координата вершины при этом равна 2, а не 1.

Влияние параметра масштаба на форму кривой показано на рисунке 1.

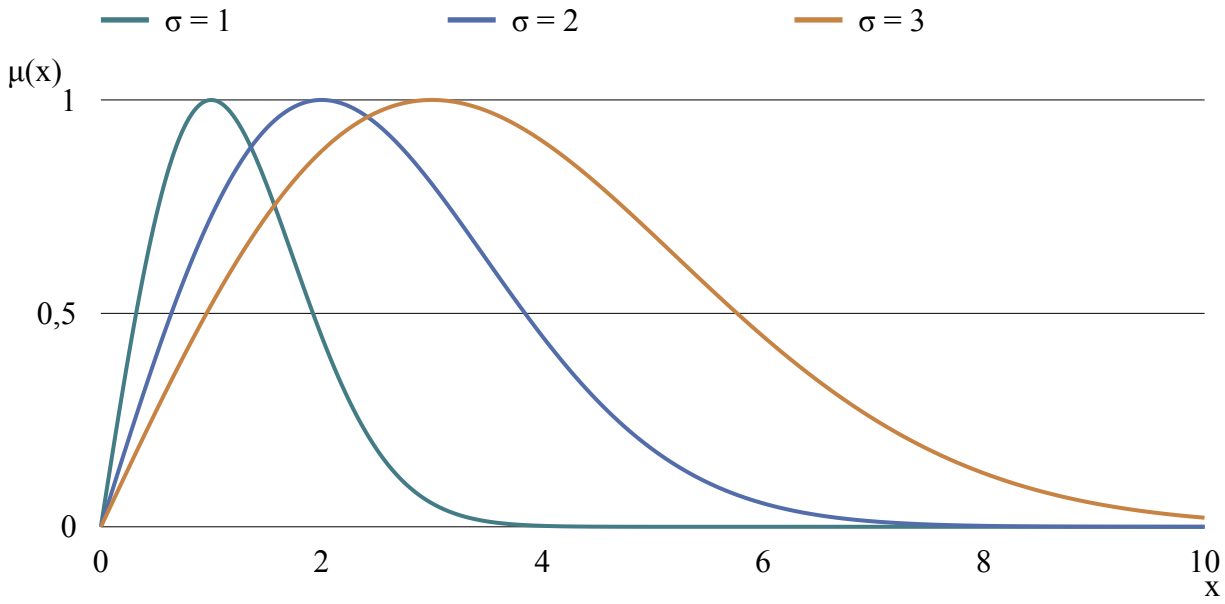


Рисунок 1 - Влияние параметра σ на функцию принадлежности

μ(x) = 0,5 означает степень принадлежности 0,5, а не вероятность 50%. Площадь под μ не обязана равняться 1. Программа не оценивает вероятность попадания в интервал и не обучает вероятностную модель по наблюдениям.

2.3 Представление через α-срезы

α-срез объединяет значения x, принадлежность которых не меньше выбранного α. Для кривой Рэлея он является замкнутым интервалом [3]:

$$A_\alpha = \{x : \mu_A(x) \geq \alpha\} = [L_A(\alpha), U_A(\alpha)],\ 0 < \alpha \leq 1. \quad (5)$$

где Aα - α-срез нечёткой величины A;

μA(x) - функция принадлежности;

LA(α), UA(α) - левая и правая границы среза;

α - уровень принадлежности.

При росте α левая граница движется вправо, а правая - влево. Поэтому срезы вложены. При α = 1 интервал вырождается в точку [σ; σ]. Это также является проверкой нормальности функции принадлежности: её максимальное значение равно 1.

Как находятся границы. Вводится безразмерная переменная t = x/σ. Находятся два корня уравнения $t \cdot \exp[(1 - t^2)/2] = \alpha$. Левый корень ищется на [0; 1], правый - справа от 1. Правая граница поиска удваивается, пока корень не окажется заключён в интервале. Библиотека использует метод Брента; найденные корни умножаются на σ.

Соответствующие сведения приведены в таблице 2.

Таблица 2 - Границы срезов при σ = 2

α	L(α), σ = 2	U(α), σ = 2
0,001	0,001213	8,411521
0,1	0,121530	5,527514
0,5	0,638211	3,843246
0,9	1,389988	2,680775
1	2,000000	2,000000

Почему используется ε. Исходная функция имеет бесконечный правый хвост. Для численных операций задаются 401 равномерный уровень от ε = 0,001 до 1. Принадлежности ниже ε не участвуют в арифметике и интегральных характеристиках. Это конечное приближение с явно заданным порогом, который сохраняется в JSON.

RayleighFuzzy вычисляет исходный срез по корням уравнения. AlphaCutFuzzy хранит массивы α, L и U; между узлами границы линейно

интерполируются. Отсечённый хвост нельзя восстановить простым уменьшением ε у уже сохранённого результата.

В живом графике браузер пересчитывает корни бисекцией на каждом событии input. Окончательный уровень передаётся в Python после отпускания ползунка. Это позволяет видеть движение среза без ожидания перезапуска всего интерфейса.

2.4 Арифметические операции

На каждом рабочем уровне α берутся два интервала $A_\alpha = [a; b]$ и $B_\alpha = [c; d]$. Операция выполняется над ними по правилам интервальной арифметики [3]. Результат всех 401 операций образует новую нечёткую величину.

Это реализация принципа расширения с min для совместной принадлежности независимых аргументов: для результата z рассматриваются все пары x, y с $x \circ y = z$ и выбирается наибольшее $\min(\mu A(x), \mu B(y))$. Выпуклые срезы позволяют выполнять этот расчёт через интервалы.

Соответствующие сведения приведены в таблице 3.

Таблица 3 - Правила интервальной арифметики

Операция	Правило для одного α-среза
Сложение	[a + c; b + d]
Вычитание	[a - d; b - c]
Умножение	[min(ac, ad, bc, bd); max(ac, ad, bc, bd)]
Деление	[min(a/c, a/d, b/c, b/d); max(a/c, a/d, b/c, b/d)], если $0 \notin [c; d]$

В формульной записи вычисление выполняется отдельно для каждого уровня α. Для произведения и частного сначала составляются множества четырёх комбинаций концов:

$$
\begin{aligned}
(A + B)_\alpha &= [a + c;\ b + d],\\
(A - B)_\alpha &= [a - d;\ b - c],\\
(A \times B)_\alpha &= [\min P;\ \max P],\\
(A / B)_\alpha &= [\min Q;\ \max Q],\ 0 \notin [c;\ d].
\end{aligned}
\tag{6}
$$

где a, b - границы среза Aα; c, d - границы среза Bα;

P = {ac, ad, bc, bd} - произведения концов;

Q = {a/c, a/d, b/c, b/d} - частные концов.

Все четыре комбинации концов при умножении и делении нужны для корректной обработки отрицательных результатов. Если хотя бы один рабочий срез знаменателя содержит ноль, деление отклоняется с сообщением об ошибке.

Контрольный расчёт. Для σA = 1, σB = 2 и α = 0,5 исходные интервалы приблизительно равны [0,319106; 1,921623] и [0,638211; 3,843246]. Численные результаты библиотеки:

Соответствующие сведения приведены в таблице 4.

Таблица 4 - Результаты операций при α = 0,5

Операция	Левая граница	Правая граница
A + B	0,957318	5,764870
A - B	-3,524141	1,283412
A × B	0,203658	7,385277
A / B	0,083030	3,010969

Для результата уровень 0,5 может лежать между узлами сетки, поэтому применяется интерполяция. Это объясняет небольшое отличие от арифметики над исходными точными границами при том же α.

На уровне α = 1 расчёт особенно прост: для σA = 1 и σB = 2 срезы равны [1; 1] и [2; 2]. Подстановка в правила даёт A + B = [3; 3], A - B = [-1; -1], A × B = [2; 2] и A / B = [0,5; 0,5]. Так получаются координаты вершин результатов.

Принадлежность в этих вершинах остаётся равной 1. По принципу расширения пара вершин исходных величин имеет совместную

принадлежность min(1, 1); выше единицы функция принадлежности подняться не может:

$$z_0 = \sigma_A \circ \sigma_B,$$
$$\mu_C(z_0) \geq \min(1, 1) = 1, \quad (7)$$
$$\mu_C(z_0) \leq 1 \Rightarrow \mu_C(z_0) = 1.$$

где z0 - координата вершины результата C;

◦ - выбранная операция сложения, вычитания, умножения или деления;

μC - функция принадлежности результата.

Как хранится результат. Результат имеет тип AlphaCutFuzzy и хранит собственную форму. После умножения или деления программа не пытается подобрать к нему новый σ. Сохранённый результат C001 можно использовать в следующей операции.

Операнды трактуются как независимые нечёткие величины в смысле интервального расширения. Если выбрать один объект дважды, A - A обычно даст интервал, а не точный ноль: зависимость двух вхождений одного x здесь не моделируется.

2.5 Сравнение и расстояние

Ранжирование. В работе выбран один явно заданный способ упорядочивания: среднее по α значение центра среза. Это скалярная характеристика положения величины, а не вероятность и не полное описание её формы.

$$r(A) = [1 / (1 - \varepsilon)] \int_{\varepsilon}^{1} (L_A(\alpha) + U_A(\alpha)) / 2 \, d\alpha. \quad (8)$$

где r(A) - ранг нечёткой величины A;

ε - нижний рабочий уровень принадлежности;

LA(α), UA(α) - границы среза на уровне α.

Интеграл вычисляется методом трапеций на рабочей сетке. Сравниваются r(A) и r(B); для практически равных значений применяется

относительный допуск $10^{-9}\cdot\max(1,\ |r(A)|,\ |r(B)|)$. Равенство рангов не гарантирует равенства функций принадлежности.

Как интеграл считается в коде. Центры срезов вычисляются на равномерной сетке. Площадь под графиком центров приближается суммой площадей трапеций:

$$\begin{gathered} h = (1 - \varepsilon)/(m - 1),\ \alpha_i = \varepsilon + ih, \\ c_i = [L_A(\alpha_i) + U_A(\alpha_i)]/2, \\ r(A) \approx [h/(1 - \varepsilon)] \cdot [c_0/2 + \Sigma_{i=1..m-2}\, c_i + c_{m-1}/2]. \end{gathered} \tag{9}$$

где h - шаг сетки; ε - нижний рабочий уровень;
m - число уровней, в программе m = 401;
αi - уровень с номером i от 0 до m - 1;
ci - центр среза на этом уровне.

При ε = 0,001 получается h = 0,0024975. Деление на 1 - ε превращает интеграл в среднее по рабочему диапазону α: если все центры равны одному числу c, ранг тоже равен c. Верхняя граница интегрирования 1 обозначает максимальный уровень принадлежности.

После получения двух рангов сравнение сводится к проверке их разности с учётом допуска:

$$\begin{gathered} \delta = r(A) - r(B), \\ \tau = 10^{-9}\ \max(1, |r(A)|, |r(B)|), \\ A < B \text{ при } \delta < -\tau;\ A = B \text{ при } |\delta| \le \tau; \\ A > B \text{ при } \delta > \tau. \end{gathered} \tag{10}$$

где δ - разность рангов;
τ - численный допуск;
знаки сравнения относятся к выбранному ранжированию.

Для σA = 1 и σB = 2 имеем r(A) ≈ 1,174651, r(B) ≈ 2,349302, δ ≈ -1,174651 и $\tau \approx 2{,}349302\cdot10^{-9}$. Разность отрицательна и по модулю значительно больше допуска, поэтому программа выводит A < B. При сравнении A с собой δ = 0, следовательно, выводится равенство по рангу.

Расстояние между нечёткими величинами. Для кластеризации учитывается различие обеих границ на всём рабочем диапазоне α. В реализации используется среднеквадратичное расстояние:

$$D(A, B) = \sqrt{\{ \int_{\varepsilon}^{1} \Delta^2(\alpha)\, d\alpha / [2(1 - \varepsilon)] \}}. \quad (11)$$

где D(A, B) - расстояние между величинами;

$\Delta^2(\alpha) = [LA(\alpha) - LB(\alpha)]^2 + [UA(\alpha) - UB(\alpha)]^2$;

LA, LB, UA, UB - границы срезов величин A и B;

ε - порог отсечения хвоста.

Расстояние равно нулю для совпадающих срезов и увеличивается при расхождении границ. Для матрицы расстояний границы умножаются на квадратные корни весов метода трапеций. Евклидово расстояние между полученными векторами даёт ту же формулу.

Соответствующие сведения приведены в таблице 5.

Таблица 5 - Сравнение величин с σA = 1 и σB = 2

Пример: σA = 1, σB = 2	Значение
Ранг A	1,174651
Ранг B	2,349302
Отношение по рангу	A < B
D(A, B)	1,495936
Пересечение срезов при α = 0,5	[0,638211; 1,921623]

Почему график кластеров одномерный. У исходных величин $L\sigma(\alpha) = \sigma \cdot L1(\alpha)$ и $U\sigma(\alpha) = \sigma \cdot U1(\alpha)$. Подстановка в формулу даёт $D(A, B) = C \cdot |\sigma A - \sigma B|$, где $C \approx 1{,}495936$ для текущей сетки. Поэтому единственный независимый числовой признак семейства - σ. Вертикальная ось диаграммы показывает категории кластеров.

Перекрытие на одном уровне 0,5 является дополнительной наглядной характеристикой. Оно не заменяет интегральное расстояние и само по себе не задаёт правило объединения.

3 Кластеризация полной связью

Кластеризация группирует близкие нечёткие величины. Основной алгоритм является агломеративным: он начинает с отдельных объектов и последовательно объединяет группы. Исходные метки генератора алгоритму не передаются.

3.1 Последовательность вычислений

Соответствующие сведения приведены в таблице 6.

Таблица 6 - Этапы иерархической кластеризации

Шаг	Действие
1	Для всех пар вычислить D(A, B) по α-срезам; получить симметричную матрицу
2	Считать каждый из N объектов отдельным кластером
3	Для каждой пары кластеров определить расстояние полной связи
4	Объединить пару с минимальным расстоянием, пересчитать связи
5	Повторять до единственного корня; сохранить дерево из N - 1 объединений
6	Разрезать дерево по K или T; перенумеровать группы по среднему рангу

$$D_{complete}(G, H) = \max \{ D(A, B) : A \in G, B \in H \}. \quad (12)$$

где Dcomplete(G, H) - расстояние полной связи между группами G и H; D(A, B) - расстояние между объектами A и B.

Полная связь оценивает самую далёкую пару между двумя группами [4]. Она предпочитает компактные группы и не сводится к сравнению только ближайших соседей. В SciPy используется linkage(..., method='complete').

3.2 Три способа остановки

Соответствующие сведения приведены в таблице 7.

Таблица 7 - Режимы разрезания дерева

Режим	Смысл результата
Ровно K	Выполнить N - K объединений. Даже при одинаковых расстояниях получить ровно K групп; K = 1 и K = N допустимы
Порог T	Оставить объединения на высоте не больше T. При увеличении T группы могут сливаться, но не дробятся
Авто (Gap)	Сначала оценить подходящее K по контрольным наборам, затем разрезать то же дерево

Дендрограмма показывает высоту объединений. Резкий скачок перед слиянием крупных ветвей указывает на заметный разрыв расстояний. Это полезный диагностический признак, но не доказательство единственно правильного разбиения.

В пороговом режиме диаметр каждой группы не превышает T с учётом численной погрешности. В режиме ровно K такого порогового ограничения нет. При K больше числа различных объектов одинаковые величины могут оказаться в разных группах ради выполнения условия ровно K.

3.3 Выбор числа групп по Gap

Автоматический режим сравнивает компактность групп с тем, что получилось бы у данных без специально заложенных сгущений. Контрольная модель - равномерное распределение σ между минимумом и максимумом исходного набора.

Критерий. Для каждого K строится разбиение полной связью и вычисляется внутригрупповой разброс W(K): сумма квадратов отклонений σ от среднего своей группы. Чтобы единицы измерения не влияли на вычисления, σ предварительно переводятся в диапазон [0; 1].

$$W(K) = \Sigma_{g=1..K} \Sigma_{i \in Gg} (\sigma_i - \bar{\sigma}_g)^2.$$
$$Gap(K) = \text{mean}[\ln W_{ref}(K)] - \ln W(K). \quad (13)$$

где W(K) - внутригрупповой разброс для K кластеров;
Gg - множество объектов группы g;
σi - нормированный параметр объекта i;
σ̄g - среднее значение параметра в группе g;
Wref(K) - разброс в контрольном наборе;
mean - среднее по контрольным наборам.

Генерируются B = 100 контрольных наборов такого же размера. Каждый также делится полной связью. Чем больше Gap, тем сильнее компактность реальных групп превосходит контрольную модель [5, 6]. Общий множитель C^2 из расстояния по срезам сокращается в разности логарифмов.

Правило, реализованное в программе. Просматриваются K от 1 до min(10, N - 1, числа различных σ). Находится K* с наибольшим Gap. Затем берётся наименьшее K, значение которого не хуже максимума более чем на одну оценку погрешности:

$$s(K) = SD[\ln W_{ref}(K)] \cdot \sqrt{(1 + 1/B)}.$$
$$K_{выбр} = \min \{K : Gap(K) \geq Gap(K^*) - s(K^*)\}. \quad (14)$$

где s(K) - оценка погрешности критерия Gap;
SD - выборочное стандартное отклонение;
B - число контрольных наборов;
K* - число кластеров с максимальным Gap;
Kвыбр - выбранное число кластеров.

Это вариант global 1-SE, соответствующий правилу globalSEmax, а не правило сравнения только соседних K. Он позволяет предпочесть более простое разбиение, когда прибавка качества укладывается в разброс контрольного эксперимента. Seed контрольных наборов фиксирован: 42.

Почему может получиться одна или три группы. Если деление равномерного набора не даёт убедительного выигрыша относительно

случайного контроля, допустимо K = 1. У трёх хорошо разделённых скоплений W(3) резко уменьшается, и выбираются три группы. Выбросы могут создать дополнительные небольшие ветви: на контрольном сценарии с выбросами получаются шесть групп.

$$Gap(1) \geq Gap(K^*) - s(K^*) \Rightarrow K_{выбр} = 1. \quad (15)$$

где Gap(1) - критерий для одной группы;
K* - число групп с наибольшим Gap;
s(K*) - допуск глобального правила 1-SE.

Если условие выполнено, число 1 уже входит в допустимый набор кандидатов и является его наименьшим элементом. Поэтому выбирается одна группа. Это результат правила выбора K, а не значение принадлежности или показателя ARI.

Для совпадающих величин и наборов меньше трёх объектов предусмотрена одна группа. Достижение верхней границы поиска отмечается в диагностике. Gap является оценкой относительно выбранной контрольной модели, а не знанием числа источников генерации.

3.4 Сравнение с HDBSCAN

HDBSCAN получает те же объекты и ту же матрицу D, что и полная связь. Он выделяет устойчивые плотные скопления и может оставить часть объектов шумом. Число групп и один фиксированный радиус пользователем не задаются [7, 8].

Логика работы. Для объекта определяется core-расстояние до k-го соседа. В соглашении scikit-learn сам объект включён в счёт k. Расстояние взаимной достижимости двух объектов определяется так:

$$D_{mr}(A, B) = \max \{ core_k(A), core_k(B), D(A, B) \}. \quad (16)$$

где Dmr(A, B) - расстояние взаимной достижимости;
corek(A), corek(B) - расстояния до k-го соседа;
D(A, B) - исходное расстояние между объектами.

На этой основе строится иерархия связности при разных масштабах плотности. Мелкие ветви сокращаются по минимальному размеру, затем метод EOM выбирает устойчивые группы. Разреженная перемычка поэтому не обязана склеивать плотные скопления.

Соответствующие сведения приведены в таблице 8.

Таблица 8 - Настройки HDBSCAN

Настройка	Начальное значение	Как читать
Минимальный размер группы	10	Более мелкое скопление не становится самостоятельной группой
Соседей для оценки плотности	10	Большее значение обычно делает выделение плотных областей строже
Разрешить одну группу	Да	Позволяет выбрать одну группу; часть объектов всё равно может остаться шумом

Пример расхождения методов. Сценарий «Группы и выбросы», N = 150, seed = 42: полная связь с Gap даёт 6 групп, HDBSCAN - 3 группы и 8 объектов шума. Полная связь распределяет все объекты; HDBSCAN может отказаться от разреженных объектов. В генераторе задано 12 выбросов: четыре из них присоединились к найденным группам.

В приложении шум имеет номер 0 и показан серыми крестиками. Он не входит в число кластеров. У scikit-learn исходная метка шума равна -1; адаптер переводит её в 0. Номера обычных групп локальны для каждого метода.

При N меньше любого из двух минимумов весь набор считается шумом. Полностью совпадающие объекты образуют одну группу, если она разрешена; иначе возвращается шум. Дендрограмма в интерфейсе относится только к полной связи.

3.5 Отбор по соответствию кластеру

Отбор выполняется после получения исходного разбиения. Для каждой группы центр Cg строится как среднее левых и среднее правых границ её α-срезов на каждом уровне сетки. В семействе Рэлея без сдвига такой центр имеет параметр σ, равный среднему σ группы.

$$s_g^2 = (1 / n_g) \sum_{i \in g} D(A_i, C_g)^2. \quad (17)$$

где s_g - среднеквадратичный радиус группы;
n_g - исходный размер группы;
$D(A_i, C_g)$ - расстояние от величины до центра по срезам.

$$u_i = \exp(-D(A_i, C_g)^2 / (2s_g^2)). \quad (18)$$

где u_i - оценка соответствия объекта своей группе;
$s_g > 0$ - радиус исходной группы.

Оставляют объекты с $u_i \geq \alpha$, где $0 \leq \alpha \leq 1$. У центра оценка равна 1. На расстоянии одного радиуса она примерно равна 0,607. Нулевой разброс означает совпадение объектов: все получают 1. При $\alpha = 1$ остаются только совпадения с центром с учётом машинной точности; исходная группа может опустеть.

Например, в одной группе с σ = 1, 2 и 3 центр имеет σ = 2. Расстояние D пропорционально разности σ, поэтому у крайних объектов отношение $D^2 / (2s^2)$ равно 3/4. Оценки равны 0,472367; 1; 0,472367. При $\alpha = 0,5$ проходит только средний объект.

Оценка относительна к разбросу своей группы. Она не является вероятностью, оценкой HDBSCAN или правилом переназначения объектов. Отсечённый объект остаётся в исходном наборе и сохраняет номер группы. Шум HDBSCAN не имеет оценки и не участвует в построении центров. Порог отбора не изменяет α-срезы входных величин, число найденных групп и ARI.

4 Моделирование набора

Генератор создаёт значения σ для разных нечётких величин. На основе каждого σ строится собственная кривая Рэлея. Если σ разыгрывается из нормальной смеси, это меняет расположение кривых в наборе, но не превращает сами кривые в нормальные функции принадлежности.

Соответствующие сведения приведены в таблице 9.

Таблица 9 - Сценарии генерации набора

Сценарий	Назначение эксперимента
Три разделённые группы	Поровну объектов из [0,6; 1,2], [2,4; 3,0], [4,8; 5,4]
Один равномерный диапазон	Проверить данные без специально заложенных сгущений; границы вводит пользователь
Случайная смесь	2-6 источников; seed меняет центры, ширины и размеры
Разные размеры и ширина	Четыре источника с неодинаковым разбросом и числом объектов
Перекрывающиеся группы	Показать, что разные источники могут быть неразличимы по σ
Группы и выбросы	Три компактных источника и 8% внешних объектов
Конструктор смеси	2-8 источников, разделённость, неравномерность размеров, 0-20% выбросов

4.1 Воспроизводимость

Начальные N = 150 и seed = 42. Генератор допускает N от 100 до 300. Для смесей σ разыгрываются около центров источников; неположительные значения пересоздаются. При одинаковых параметрах и версиях библиотек один seed воспроизводит тот же набор. Seed исходного набора и seed контрольных наборов Gap решают разные задачи.

4.2 Зачем сохраняются метки источников

Генератор отдельно записывает, из какого источника получен каждый σ. Эти сведения используются только после кластеризации для проверки диаграмм и ARI. Алгоритм получает items с величинами; параметры сценария и метки ему не передаются.

Источники не являются эталоном, который всегда возможно восстановить: при сильном перекрытии один σ мог прийти из разных источников. Ручное изменение σ или добавление объекта снимает прежние исходные метки. При загрузке JSON их соответствие набору проверяется по контрольной сумме.

5 Архитектура программы

Комплекс разделён на вычислительные пакеты, интерфейс и средства запуска. Ни fuzzy_core, ни fuzzy_clustering не импортируют Streamlit или Plotly. Это позволяет использовать расчёты из внешней Python-программы.

Программа написана на Python. Streamlit формирует локальный веб-интерфейс, Plotly строит диагностические графики, а браузерные SVG-компоненты обновляют срез модели и отбор внутри кластеров. NumPy используется для массивов и интегрирования, SciPy - для корней и иерархической кластеризации, scikit-learn - для HDBSCAN. Вычислительные библиотеки работают отдельно от интерфейса.

Взаимосвязь компонентов показана на рисунке 2.

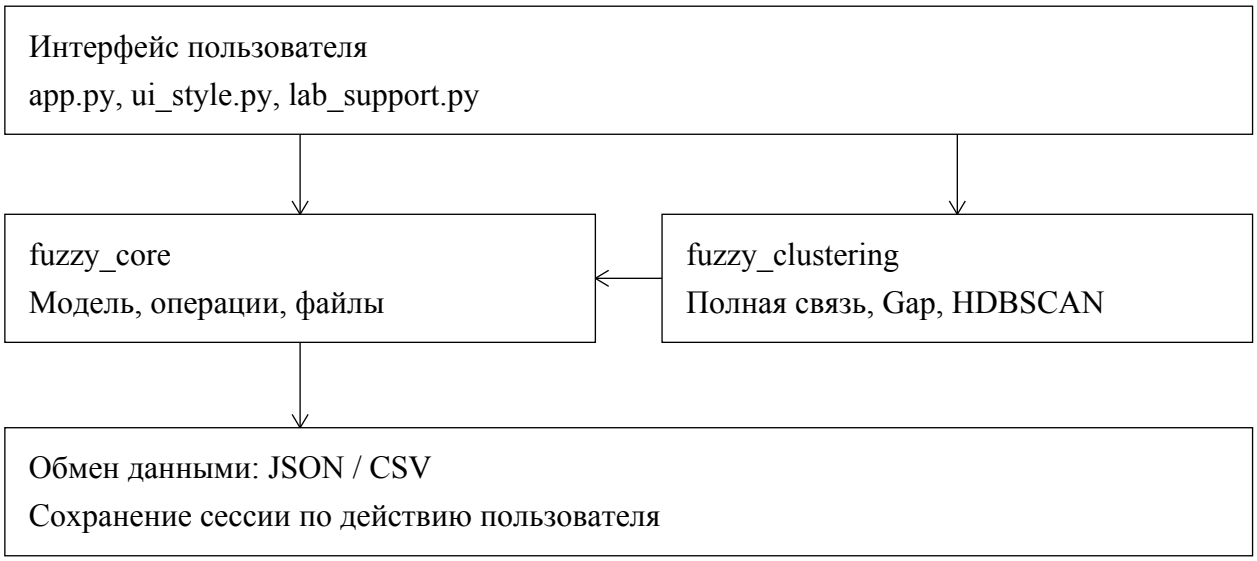


Рисунок 2 - Архитектура программного комплекса

Соответствующие сведения приведены в таблице 10.

Таблица 10 - Компоненты программного комплекса

Файл или пакет	Содержание
fuzzy_core/model.py	RayleighFuzzy, AlphaCutFuzzy, FuzzyItem, ComputationConfig; корни и интерполяция
fuzzy_core/arithmetic.py	Четыре операции, rank, distance, compare
fuzzy_core/data.py; scenarios.py	Генерация, JSON, CSV, сведения об источниках
fuzzy_clustering	distance_matrix, cluster_by_count, cluster_by_threshold, cluster_auto, cluster_hdbscan; оценки соответствия, маска отбора, ARI
app.py; ui_style.py; lab_support.py	Состояние сессии, экраны, компоновка и графики
live_model_component.py; live_clusters_component.py; ui/	SVG-графики и живое обновление двух ползунков α
manage.py; run.command; stop.command	Фоновый запуск и управление службой macOS
examples/; tests/; docs/	Примеры, проверки, документация и исходник сборки PDF

```
from fuzzy_core import RayleighFuzzy, add
from fuzzy_clustering import cluster_auto
from fuzzy_core import generate
a, b = RayleighFuzzy(1), RayleighFuzzy(2)
print(add(a, b).alpha_cut(0.5))
print(cluster_auto(generate(150, seed=42)).k)
```

6 Получение и установка программы

Проект распространяется через репозиторий MrXrel/nonclassiclogic. Можно скачать Code → Download ZIP и распаковать архив либо клонировать репозиторий командой Git:

```
git clone https://github.com/MrXrel/nonclassiclogic.git
cd nonclassiclogic
```

В корне должны находиться app.py, requirements.txt, пакеты fuzzy_core и fuzzy_clustering. Эта записка находится в docs/Пояснительная_записка.pdf, краткое руководство - в docs/Руководство.pdf. В examples/ лежат готовые JSON и CSV для воспроизведения опытов.

6.1 Требования

Нужен Python 3.12 или новее и современный браузер. Проверенная среда: Python 3.12.14, macOS arm64. Версии пакетов зафиксированы в requirements.txt. Интернет требуется при загрузке исходников и первичной установке зависимостей. Установленное приложение работает локально.

6.2 macOS и Linux: установка в виртуальное окружение

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install -r requirements.txt
```

6.3 Windows: установка без активации окружения

```
py -3.12 -m venv .venv
.venv\Scripts\python.exe -m pip install -r requirements.txt
```

Команды выполняются в папке проекта. Виртуальное окружение создаётся на конкретном компьютере и не скачивается из репозитория. На macOS run.command может выполнить его создание и установку автоматически; требуется установленный Python.

6.4 Использование только библиотек

```
python -m pip install /путь/к/nonclassiclogic
```

Эта команда устанавливает fuzzy_core и fuzzy_clustering с вычислительными зависимостями. Для запуска интерфейса отдельно нужен полный requirements.txt. Сборка самой записки необязательна: готовый PDF уже включён в комплект.

6.5 Запуск и готовность

```
python -m streamlit run app.py
```

Обычный запуск в терминале. Команда выполняется из корня с активированным окружением. Без активации на macOS/Linux можно указать .venv/bin/python, а на Windows - .venv\Scripts\python.exe. В Windows также предоставлен run.bat; его работа зависит от открытого окна терминала.

После запуска откройте http://127.0.0.1:8501/. Сервер слушает локальный интерфейс. Браузер и сервер находятся на одном компьютере. Остановка обычного запуска - Ctrl+C.

Независимый запуск на macOS. Дважды щёлкните run.command. После установки пакетов скрипт регистрирует фоновую службу launchd и открывает браузер. Закрытие Codex или окна терминала не останавливает эту службу. Для остановки используйте stop.command.

```
.venv/bin/python manage.py status
.venv/bin/python manage.py start
.venv/bin/python manage.py stop
```

Служба работает в текущем пользовательском сеансе. После выхода из учётной записи или перезагрузки откройте run.command снова. При изменении исходников остановите службу и запустите её заново. Перед переносом проекта остановите службу из прежней папки.

Признаки нормального запуска. Соответствующие сведения приведены в таблице 11.

Таблица 11 - Признаки готовности приложения

Что видно	Что это означает
Страница «Рэлей» и четыре раздела	Интерфейс загрузился, ошибок Python на странице нет
σ = 2, α = 0,5; границы около 0,638211 и 3,843246	Модель и вычисление срезов согласованы
График меняется при движении α	Браузерный компонент работает
manage.py status: «Работает»	Фоновая служба macOS отвечает по адресу приложения

Если порт 8501 занят, для обычного запуска можно добавить --server.port 8502 и открыть соответствующий адрес. manage.py использует фиксированный порт 8501; он сообщает о конфликте, а не подменяет чужой процесс. Техническая диагностика службы: runtime/server.stderr.log.

7 Работа пользователя

Разделы находятся слева, результаты - в центре, параметры - справа. В узком окне настройки перемещаются вверх; на телефоне меню сворачивается. Подробные объяснения раскрываются по запросу.

Внешний вид соответствующего раздела показан на рисунке 3.

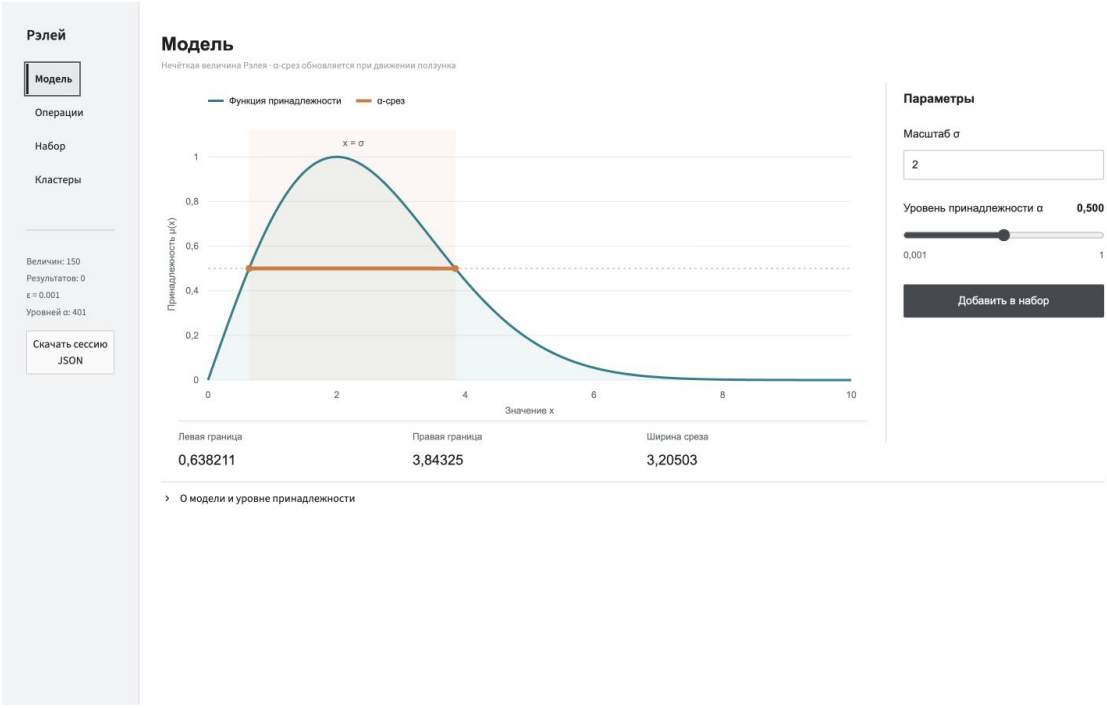


Рисунок 3 - Раздел «Модель»

7.1 Порядок работы с моделью

1) Откройте «Модель», введите положительное σ.

2) Двигайте ползунок α: срез и численные границы меняются сразу.

3) При α = 1 убедитесь, что обе границы равны σ.

4) Кнопка «Добавить в набор» создаёт объект с текущим σ; принадлежность α задаёт срез, а не новый вид объекта.

7.2 Порядок выполнения операции

1) Откройте «Операции» и задайте A и B: вручную через σ либо выбором имеющихся объектов.

2) Выберите сложение, вычитание, умножение, деление или сравнение.

3) Сопоставьте исходные кривые, результат и таблицу текущего среза. Уровень α берётся из раздела «Модель».

4) Нажмите «Сохранить результат», если хотите использовать его как следующий операнд или включить в JSON.

Флажок «Полные рабочие хвосты» расширяет видимый диапазон до ε. В обычном режиме график сфокусирован на текущем срезе. Отрицательная левая граница разности допустима. При отказе деления проверьте, не содержит ли знаменатель ноль.

7.3 Набор и кластеры

1) В разделе «Набор» справа выберите сценарий, N и seed, затем «Создать набор».

2) При необходимости измените σ в центральной таблице и нажмите «Применить изменения».

3) Перейдите в «Кластеры», выберите «Авто (Gap)», ровно K или T. Для сравнения оставьте включённым HDBSCAN и задайте его минимумы.

4) Нажмите «Рассчитать». Новые настройки применяются именно этой кнопкой.

Как читать результат. Верхняя таблица показывает число групп, шум, долю распределённых объектов и, если есть исходные метки, ARI. На двух диаграммах используется одна ось σ. Каждая точка - величина, вертикальная дорожка - категория группы. Серые крестики обозначают шум HDBSCAN.

После расчёта порог соответствия равен 0. Перетащите ползунок либо введите число, например 0,43, и нажмите Enter. Цветные точки прошли порог; серые пустые кружки находятся ниже него и остаются на строке исходной группы. Справа показано, сколько объектов осталось из первоначального числа.

Внешний вид соответствующего раздела показан на рисунке 4.

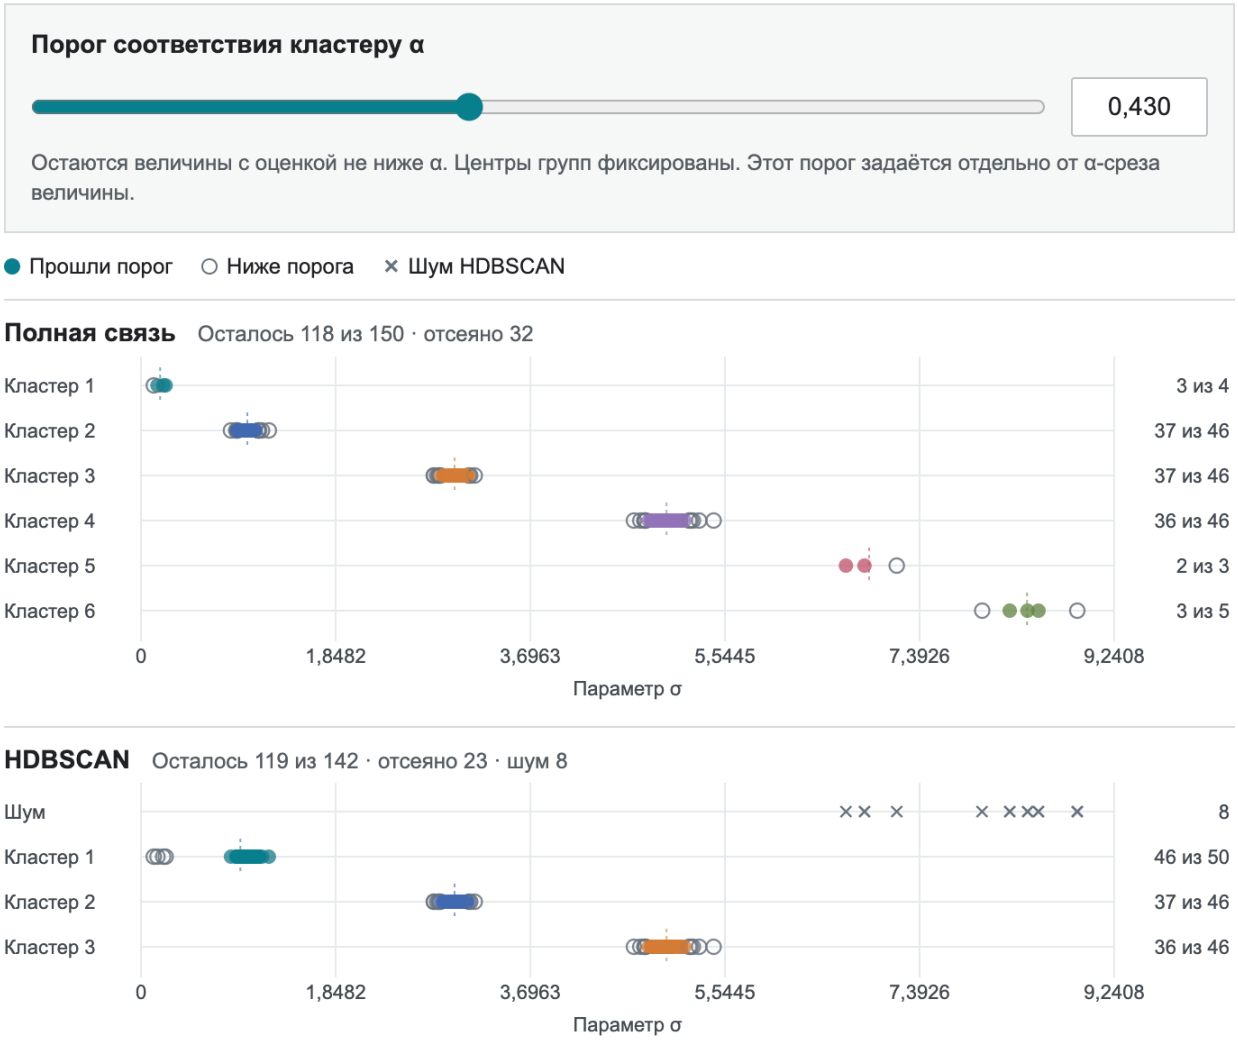


Рисунок 4 - Отбор внутри кластеров при α = 0,43

Раскройте «Состав и кривые», выберите метод и группу. Кривые ниже порога показаны серым; отображаются до 50 кривых в порядке исходного набора. Дерево, матрица расстояний, Gap и ARI описывают разбиение до отбора. Новый расчёт сбрасывает порог в 0.

Для проверки раскройте «Проверить по исходным группам»: сравните источники и найденные группы. Кнопка «Скачать CSV» выгружает таблицу; JSON доступен в меню слева. Импорт сессии: «Набор» → «Файлы» → выбрать JSON → «Загрузить сессию».

8 Проверка правильности объединения

Нормальная работа программы и содержательная полезность кластеров - разные проверки. Правильно выполненный алгоритм может дать одну группу при перекрытии или несколько мелких групп из-за выбросов. Следует сопоставлять выбранный критерий, данные и результат.

Соответствующие сведения приведены в таблице 12.

Таблица 12 - Проверка корректности разбиения

Проверка	Наблюдаемый признак
Режим ровно K	Получено ровно K групп; сумма размеров равна N
Режим порога T	Внутри каждой группы максимальное D не больше T с численным допуском; увеличение T не увеличивает число групп
Полная связь	Все N объектов имеют положительную метку, каждый входит ровно в одну группу
HDBSCAN	Число объектов в группах плюс шум равно N; метка 0 не считается отдельным кластером
График σ и кривые	В близких группах сходны σ и формы; большие пробелы по σ обычно соответствуют разрывам групп
Дендрограмма	Высоты отражают расстояния полной связи; большие скачки помогают оценить разделённость
Проверка по источникам	ARI и таблица соответствий показывают совпадения и смешение; номера групп могут различаться

8.1 Контрольные сценарии: N = 150, seed = 42

Соответствующие сведения приведены в таблице 13.

Таблица 13 - Контрольные результаты кластеризации

Сценарий	Полная связь + Gap	HDBSCAN	Шум
Три группы	3	3	0
Разные размеры	4	4	0
Перекрытие	1	1	40
Группы и выбросы	6	3	8

Для HDBSCAN используются размер 10, соседей 10 и разрешение одной группы. Это результаты конкретного набора и настроек; при изменении seed они могут измениться.

8.2 Как трактовать ARI

ARI сравнивает разбиения без зависимости от номеров групп [9]. Значение 1 означает совпадение, около 0 - согласие на уровне случайного; возможно отрицательное значение. В приложении заданные генератором выбросы исключены из ARI, а отклонённые обычные объекты остаются с меткой 0. При полном шуме ARI не выводится.

Как рассчитывается ARI. Составляется таблица соответствий: nij - число объектов, одновременно попавших в исходную группу i и найденную группу j. Суммы строк ai и столбцов bj задают размеры этих групп. Затем подсчитываются пары объектов:

$$\begin{gathered} P = \Sigma_{i,j}\, C(n_{ij}, 2), \\ P_A = \Sigma_i\, C(a_i, 2),\ P_B = \Sigma_j\, C(b_j, 2), \\ M = C(n, 2),\ E = P_A P_B / M. \end{gathered} \tag{19}$$

где $C(t, 2) = t(t - 1)/2$ - число неупорядоченных пар из t объектов;

P - число пар, объединённых в обоих разбиениях;

PA, PB - числа пар внутри групп каждого разбиения;

$n \geq 2$ - число объектов, учитываемых при проверке;

M - число всех пар; E - ожидаемое число совпадений при случайном согласии.

$$ARI = (P - E) / [(P_A + P_B)/2 - E]. \quad (20)$$

где P - наблюдаемое число совпавших пар;

E - поправка на случайное согласие;

(PA + PB)/2 - нормирующая величина для двух разбиений.

Почему получается 1. Если оба разбиения совпадают, включая случай другой нумерации групп, то P = PA = PB. Числитель и знаменатель становятся одинаковыми. Например, для трёх совпадающих групп по 50 объектов n = 150, P = PA = PB = 3·C(50, 2) = 3675 и M = C(150, 2) = 11175:

$$ARI = (3675 - 3675^2/11175) / (3675 - 3675^2/11175) = 1. \quad (21)$$

где 3675 - число пар внутри трёх групп по 50 объектов;

11175 - число всех пар из 150 объектов.

Для совпадающих вырожденных разбиений, при которых знаменатель равен нулю, реализация также возвращает 1. Таким образом, ARI = 1 означает совпадение разбиений на учтённых объектах. μ = 1 означает полную принадлежность в вершине, а K = 1 - единственный кластер; это разные смыслы единицы.

Высокий ARI следует читать вместе с долей распределённых объектов. Исходные источники при перекрытии могут быть геометрически неразличимы. Число шесть вместо трёх на выбросах поэтому само по себе не является признаком ошибки.

9 Файлы и контроль работы

9.1 Сохранение и восстановление

Соответствующие сведения приведены в таблице 14.

Таблица 14 - Форматы сохранения результатов

Формат	Содержимое и назначение
JSON	config: ε и сетка; items: величины; results: срезы результатов; clustering: основное разбиение; comparison: HDBSCAN; controls: настройки и порог cluster_alpha; generation: сведения об источниках; membership в результатах методов: правило и оценки
CSV	id, sigma, cluster; при сравнении также hdbscan_cluster и hdbscan_noise. Номер 0 и флаг 1 относятся к шуму HDBSCAN. После анализа добавляются оценка, признак прохождения порога и значение α для каждого метода
PDF	Эта пояснительная записка и отдельное краткое руководство; не содержат текущую сессию пользователя

Для продолжения работы скачайте JSON до закрытия или перезапуска. При его загрузке программа проверяет данные и пересчитывает оба анализа по сохранённым параметрам. Сохранённый порог отбора восстанавливается; в старых файлах без порога он равен 0. CSV предназначен для просмотра и внешнего анализа; обратный импорт в этой версии выполняется через JSON.

9.2 Испытания

Проверяются нормировка и корни, вложенность срезов, интервальная арифметика, отрицательная разность, отказ деления через ноль, воспроизводимость, N = 100 и 300, крайние K, одинаковые объекты, монотонность по T, Gap, HDBSCAN, сохранение и состояние интерфейса. Выполнены 125 автоматических проверок. Отдельно проверяются расчёт оценок, крайние пороги, различие отсечения и шума, обновление до отпускания ползунка и восстановление порога из JSON.

```
python -m pytest -q
python -m examples.use_libraries
python -m examples.try_scenarios
```

Для теста браузерной математики нужен Node.js; при его отсутствии проверки браузерных модулей пропускаются. Само приложение Node.js не требует. После установки Node путь можно указать переменной RAYLEIGH_NODE. Проверка интерфейса и импорта/экспорта дополнительно выполнена в браузере.

9.3 Ограничения и обработка ошибок

Генерация: 100-300 объектов; после загрузки или добавления набор может содержать 1-300. Сохраняется до 100 результатов операций. Размер JSON - до 10 МБ. Интерфейс принимает σ от 0,000001 до 1000000. Неположительные и неконечные σ, дубликаты ID, невложенные срезы и неверные версии JSON отклоняются.

Модель имеет один параметр без сдвига; выбор K в «Авто» ограничен десятью. Хвосты отсекаются по ε, интегралы и восстановление результатов являются численными приближениями. Кластеризация остаётся чёткой. Фильтр оценивает соответствие внутри исходной группы и не обнаруживает шум сам по себе. Например, одиночный кластер получает оценку 1. Изменение набора сбрасывает старый анализ.

ЗАКЛЮЧЕНИЕ

В результате работы разработан программный комплекс для представления и кластерного анализа нечётких величин формы Рэлея. Плотность нормирована по максимуму, а вычисления сведены к операциям над вложенными α-срезами с явно заданным порогом отсечения хвоста.

Реализованы четыре арифметические операции, сравнение по среднему центру срезов, интегральная метрика, воспроизводимая генерация наборов и сохранение сессий. Полная связь поддерживает заданное число групп, порог расстояния и автоматический выбор по Gap. Для исследования влияния плотности и выбросов добавлено сравнение с HDBSCAN и отбор по соответствию группе.

Вычислительные библиотеки отделены от пользовательского интерфейса. Подготовлены примеры использования, документация и автоматические проверки. На контрольном наборе из 150 величин с выбросами полная связь с Gap выделяет шесть групп, а HDBSCAN - три группы и восемь шумовых объектов. Расхождение объясняется различием критериев алгоритмов.

Полученные результаты пригодны для учебных экспериментов. Их интерпретация ограничена однопараметрической моделью без сдвига, конечной сеткой α и выбранными настройками кластеризации. Дальнейшее развитие возможно за счёт расширения семейств функций принадлежности и способов задания зависимостей между операндами.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 МАИ. Задание на комплексное практическое занятие по дисциплине «Неклассические логики». Москва, 2026.

2 NIST. Rayleigh probability density function // Dataplot. URL: https://itl.nist.gov/div898/software/dataplot/refman2/auxillar/raypdf.htm (дата обращения: 02.11.2026).

3 Lindblad J. Fuzzy numbers and fuzzy arithmetics. Uppsala University, 2010. URL: https://user.it.uu.se/~joali534/course/fuzzy/vt10/lectures/L9_4.pdf (дата обращения: 02.11.2026).

4 SciPy. scipy.cluster.hierarchy.linkage. URL: https://docs.scipy.org/doc/scipy/reference/generated/scipy.cluster.hierarchy.linkage.html (дата обращения: 02.11.2026).

5 Tibshirani R., Walther G., Hastie T. Estimating the Number of Clusters in a Dataset via the Gap Statistic. Stanford University, Technical Report BIO 208, April 2000. URL: https://statistics.stanford.edu/technical-reports/estimating-number-clusters-dataset-gap-statistic (дата обращения: 02.11.2026).

6 R package cluster. clusGap и maxSE. URL: https://stat.ethz.ch/R-manual/R-devel/library/cluster/html/clusGap.html (дата обращения: 02.11.2026).

7 Scikit-learn. HDBSCAN API. URL: https://scikit-learn.org/stable/modules/generated/sklearn.cluster.HDBSCAN.html (дата обращения: 02.11.2026).

8 Scikit-learn. Clustering: HDBSCAN. URL: https://scikit-learn.org/stable/modules/clustering.html#hdbscan (дата обращения: 02.11.2026).

9 Scikit-learn. Adjusted Rand Index. URL: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.adjusted_rand_score.html (дата обращения: 02.11.2026).

ПРИЛОЖЕНИЕ А

(справочное)

Сборка пояснительной записки

Репозиторий: https://github.com/MrXrel/nonclassiclogic. Описание архитектуры, настроек и контрольные результаты сверены с исходным кодом версии 1.6.0. Внешние документы описывают методы; порог ε, расстояние, выбранный вариант Gap и правила приложения являются решениями этой реализации.

Исходник записки: docs/build_explanatory_note.py. Для пересборки установите docs/requirements.txt и выполните python docs/build_explanatory_note.py из корня. Для сборки необходимо установить Times New Roman; при нестандартном расположении TTF-файлов задаётся переменная RAYLEIGH_TIMES_DIR. Файлы Times New Roman не распространяются вместе с проектом. Снимки экранов и дополнительные шрифты включены в docs/images и docs/fonts. Условия распространения DejaVu приведены в docs/fonts/LICENSE-DejaVu.txt.